Gestão de streaming simples com Flink

Introdução

Vamos entender conceitos de streaming e como realizar streamings menos complexos com Flink, que é uma alternativa mais simples do Apache Kafka.

Objetivos da aula

- Conhecer a ferramenta de streaming simplificado Apache Flink.
- Praticar a criação de um fluxo de streaming.

Resumo

Streaming de dados é um conceito importante para quase todas as vertentes da tecnologia. Por isso, antes de entendermos o que é e como funciona Apache Flink ou Apache Kafka, vamos entender o conceito por trás de ambos, pois assim ficará muito mais fácil de entender, escolher e implementar qualquer uma das ferramentas.

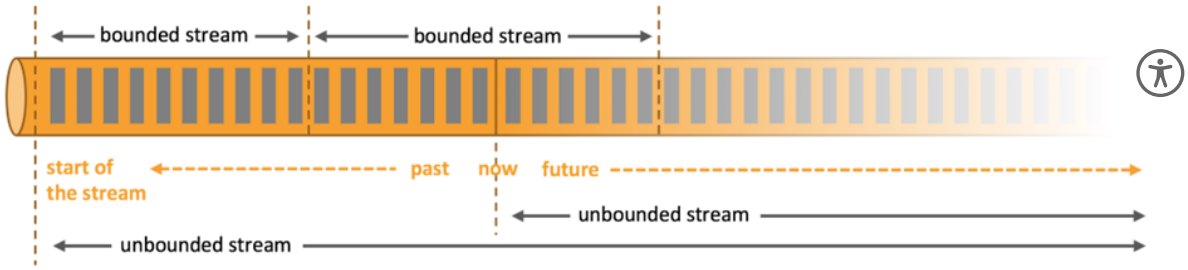
Vamos começar a entender o que são fluxos de dados. Aplicações menos sofisticadas usam sistemas de armazenamento mais simples e menos rápidos, pois não exigem alta velocidade de transmissão e

disponibilidade de dados. Isso acontecia por conta da baixa demanda em tempo real dos dados, uma vez que as aplicações-cliente, ou seja, as consumidoras dos dados, não precisavam de dados de forma tão rápida e disponível o tempo todo. Para estas aplicações, bases de dados convencionais faziam um trabalho excelente.

Com o tempo, começamos a aprimorar as aplicações-cliente ao ponto que um aplicativo de transporte no celular de uma jovem estudante acessa milhares de dados espalhados por diferentes servidores no mundo todo. Com essa evolução e alta demanda de qualidade, disponibilidade e velocidade de transmissão de dados, nasceram os sistemas de streaming de dados, que processam grandes volumes de dados em tempo real e torna disponível o resultado do processamento para diferentes plataformas e praticamente qualquer necessidade.

A imagem abaixo ilustra o conceito de fluxos limitados e ilimitados. Todo fluxo de dados terá um início, ou seja, um dado inicial que será extraído de uma base ou aplicação e será transformado e combinado com outros dados para posterior operações e necessidades diversas. A diferença entre um fluxo de dado limitado e um fluxo ilimitado é o fato do primeiro ter um fim planejado enquanto a segunda não necessariamente tenha. Em outras palavras, um fluxo limitado ou *bounded stream* já tem seu início, meio, propósito e fim definidos enquanto um fluxo ilimitado ou *unbounded stream* tem início e propósitos iniciais definidos, mas não tem necessariamente um fim nem limites para seus propósitos alternativos.

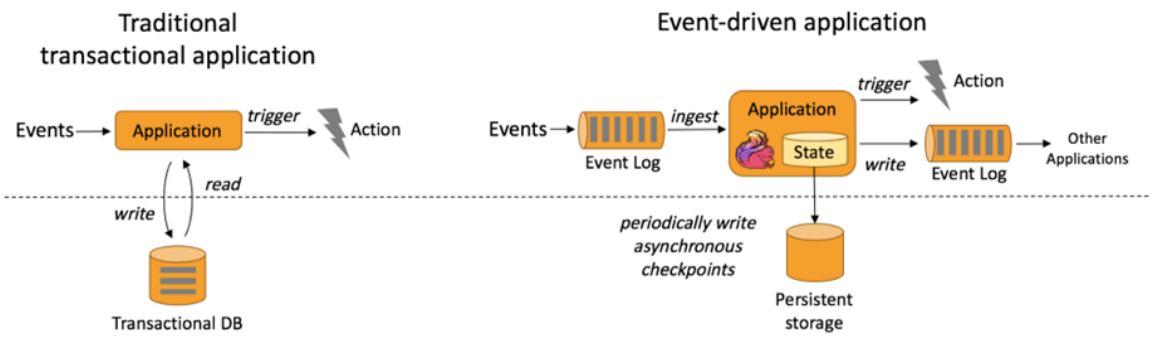
Imagem 1. fluxos de dados limitados e ilimitados.



Fonte: https://flink.apache.org/. (acesso em 21/12/2022)

Vamos exemplificar os dois casos. Um exemplo de um fluxo de dados limitado seria um ETL convencional, ou seja, uma extração, transformação e carregamento de dados de forma automatizada mas com uma clara definição de onde o dado será extraído, quais transformações podem ocorrer no dado, onde o dado será usado e finalmente armazenado. Podemos comparar com processamento em batch ou em lote. Um fluxo de dados ilimitados é como uma fonte de água contínua que permite que os dados de tal fluxo possam ser reutilizados por diferentes aplicações com diferentes propósitos. Um potencial exemplo disso seriam os dados gerados por um usuário de um aplicativo como Uber, por exemplo. Os dados podem ser armazenados, mas são disponíveis em tempo real para diferentes outros propósitos em tempo real. Seja para anúncios, novas corridas, recomendações, cálculos de rota e valores.

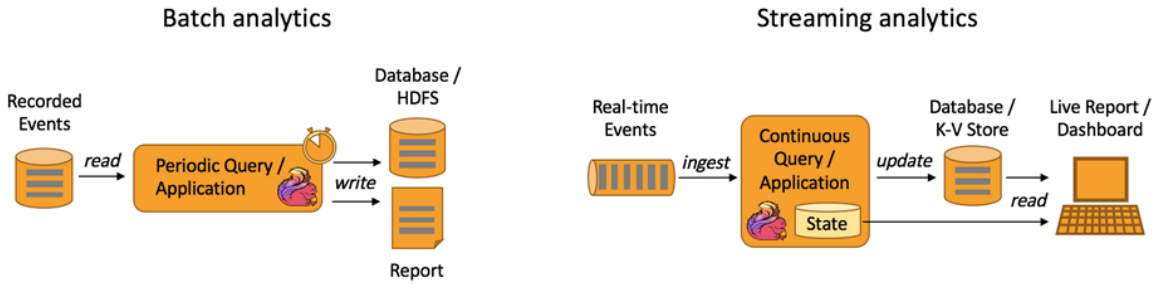
Imagem 2. Aplicações tradicionais vs. Aplicações dirigidas por eventos.



Fonte: https://flink.apache.org/. (acesso em 21/12/2022)

A imagem acima é uma forma visual de entender essa evolução entre aplicações mais rígidas e menos velozes comparadas com aplicações mais ágeis e orientadas a eventos. Veja que o armazenamento de dados é um objeto separado do ciclo de vida da aplicação e funciona até como um fator de atraso. Já nas aplicações mais modernas que contam com streaming ou tecnologias similares, o armazenamento acontece em forma paralela em discos mais rápidos de forma permanente com pontos de checagem que armazenam o estado dos dados antes de cada operação, o que aumenta a segurança e integridade dos dados em casos de erros e trabalha também em memória RAM para uso imediato de forma extremamente ágil.

Imagem 3. Estruturas internas de processamento em Batch e Streaming.



Fonte: https://flink.apache.org/. (acesso em 21/12/2022)

Agora vamos tentar entender melhor o que é o Apache Flink. Mecanismo de processamento de dados em larga escala rápido e confiável. O Apache Flink é um sistema de código aberto para análises de dados versáteis em clusters. Esta solução oferece suporte a análises de lote (batch) e streaming em uma única estrutura. A parte interessante

de Flink é que seus jobs de análise de dados podem ser escritos em APIs em linguagem Java e Scala.

Muitas pessoas confundem Flink com Kafka. É importante entender a diferença. Resumidamente, Flink seria uma versão mais enxuta e mais fácil de gerenciar com alguns serviços similares ao de Kafka. Kafka pode ser definido como um sistema de mensagens distribuídas, tolerante a falhas e de alto rendimento. Kafka é um serviço de log de commit distribuído, particionado e replicado. É possível até implementar algumas funcionalidades de Kafka dentro de Flink para maior desempenho.

Ambas ferramentas se conectam com diversas fontes de dados como bancos de dados relacionais e diversos outros e processam os dados conforme as necessidades de diferentes eventos e aplicações, sempre mantendo os dados originais intactos quando necessário e armazenando os dados processados de uma forma extremamente acessível, confiável e rápida.

Como aplicar na prática o que aprendeu

Dependendo de qual será sua atuação, é importante entender o nível de profundidade que você precisa ter na infraestrutura técnica, na criação de jobs e até na instalação da plataforma.

Como criar jobs para Flink. https://www.baeldung.com/apache-flink.

Entenda como Netflix usa Flink. https://www.infoq.com/news/2022/04/netflix-studio-search/.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Configurando jobs de sincronização de dados em Java. https://www.youtube.com/watch?v=9YvC7QAclbs.

Conceitos avançados de streaming com códigos prontos. https://www.baeldung.com/kafka-flink-data-pipeline.

Flink tutoriais (explore Github para mais). https://github.com/luweizheng/flink-tutorials.

Referência Bibliográfica

Flink Use cases. **Apache Foundation.** 2022. Disponível em: https://flink.apache.org/usecases.html. Acesso em 21/12/2022

Flink Architecture. 2022. Disponível em: https://flink.apache.org/flink-architecture.html. Acesso em 21/12/2022

STILLER. Eran. Netflix Studio Search: Using Elasticsearch and Apache Flink to Index Federated GraphQL Data. **InfoQ**. 2022. Disponível em:

https://www.infoq.com/news/2022/04/netflix-studio-search/. Acesso em 21/12/2022

QADAH. Ehab. Netflix Studio Search: Using Elasticsearch and Apache Flink to Index Federated Towards Data Science. **Data.** 2022. Disponível em: https://towardsdatascience.com/an-introduction-to-stream-processing-with-apache-flink-b4acfa58f14d. Acesso em 21/12/2022

Ir para questão