Movimentação de dados interplataformas com Sqoop

Introdução

Vamos entender como funciona a movimentação entre bases de dados relacionais e o ambiente Apache / Hadoop com Sqoop e outras alternativas. Também entenderemos o que é o Apache Attic e como funciona a aposentadoria de soluções Apache.

Objetivos da aula

- Conhecer a ferramenta de migração de dados Apache Sqoop.
- Entender o que é Attic e praticar a migração de dados.

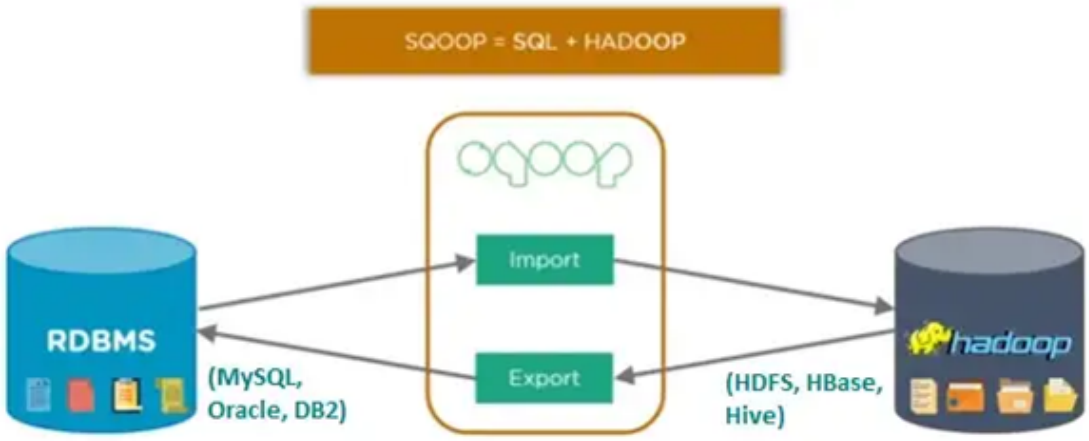
Resumo

Apache Sqoop ou SQL para Hadoop é uma solução da família Apache responsável pela migração de dados entre bases de dados relacionais (SQL) e o ambiente Apache, geralmente através do Hadoop. É importante notar que esta solução já está aposentada, ou seja, não haverá mais atualizações nem novas melhorias para o Sqoop. Quando uma ferramenta da família Apache é descontinuada, ela é enviada para o que chamamos de "sótão" ou *attic* em Inglês.

Quando uma solução vai para o Apache *Attic*, ela não é mais recomendada para novos projetos, mas isso não significa que ela deixará de funcionar. Este é o caso de Sqoop. A ferramenta não é mais recomendada para novos projetos, mas todos os projetos que ainda o utilizam, podem continuar sua utilização sem preocupação. Novos projetos, porém, podem contar com diversas outras alternativas já nativas do Apache Spark, Flume e o próprio Kafka Connect, que já contam com esta solução de migração de dados nativamente.

Cada uma destas soluções têm seus prós e contras, por isso é importante entender suas vantagens e desvantagens antes de começar um novo projeto com elas. Vamos começar com o Sqoop.

Imagem 1. Arquitetura geral do Apache Sqoop.



Fonte: Apache Foundation. (acesso em 21/12/2022)

Entre 2009 e 2017, Apache Sqoop foi a principal solução para transmissão de dados entre bases de dados relacionais de diferentes plataformas, desde microcomputadores até grandes mainframes.

Ele se tornou necessário por conta da grande diferença na arquitetura dos dados do ambiente Hadoop, o Hadoop Distributed File Syste (HDFS) e a arquitetura em bases de dados relacionais. É importante entender a diferença entre essas arquiteturas de arquivos para entender a necessidade de soluções como Sqoop e ter a habilidade decisória na hora de implementar ou atualizar uma nova solução de Big Data.

Para ilustrar a diferença entre os tipos de arquivos, imagine que você está tentando abrir um arquivo de imagem com o programa de anotações do Windows chamado “Bloco de Notas”.

Você até pode conseguir abrir o arquivo sem ajuda de outras aplicações, mas os dados exibidos não farão sentido algum. O que aplicações como Sqoop fazem é mais do que apenas converter um documento de texto para PDF, por exemplo. Este tipo de conversão não altera necessariamente o conteúdo do arquivo original. O que estas soluções como Sqoop fazem é a criação de significado para a plataforma-destino. Sqoop pode usar até Map e Reduce ao exportar dados para gerar maior inteligência e até identificar linhas de forma mais apropriada, alterando assim a estrutura geral dos dados quando necessário.

A analogia que mais funcionou em aulas que ministrei até o momento é a seguinte:

Imagine que você quer abrir uma imagem com o Bloco de notas. Ao fazê-lo, você nota que o arquivo de imagem não foi otimizado para o bloco de notas e, por isso, acaba vendo milhares de linhas de texto que não fazem sentido para você. O que Sqoop faria, neste caso, é a conversão da imagem para texto em seu idioma, que descreve a imagem de uma forma que faça tanto sentido quanto visualizar a imagem.

Espero que a analogia funcione para você também, pois este é um conceito muito importante da gestão de dados e, resumidamente, o q quis dizer é que Sqoop não apenas converte os dados para que apareçam na plataforma-destino, mas também ajuda os dados a gerar a mesma quantidade de valor ou até mais valor na plataforma-destino.

Tabela 1. Diferenças entre HDFS e Sistema de Arquivos relacionais.

Banco de Dados Relacional	Hadoop Distributed File System (HDFS)
Bancos de dados tradicionais baseados em linha-coluna, basicamente usados para armazenamento, manipulação e recuperação de dados.	Um software de código aberto usado para armazenar dados e executar aplicativos ou processos simultaneamente.
Dados estruturados são principalmente processados.	Ambos os dados estruturados e não estruturados são processados.
É mais adequado para o ambiente OLTP (Processamento de transações online.)	É mais adequado para BIG data.
É menos escalável que o Hadoop.	É altamente escalável.
A normalização de dados é necessária.	A normalização de dados não é necessária no Hadoop.
Ele armazena dados transformados e agregados.	Ele armazena grande volume de dados.
Não tem latência na resposta.	Tem alguma latência na resposta.
O esquema de dados do RDBMS é do tipo estático.	O esquema de dados do Hadoop é do tipo dinâmico.
Alta integridade de dados disponível.	Geralmente menor integridade de dados disponível do que RDBMS (bancos relacionais).
O custo é aplicável para software licenciado.	Gratuito, pois é um software de código aberto.

Fonte: https://www.geeksforgeeks.org/difference-between-rdbms-and-hadoop/ (acesso em 21/12/2022)

Com a evolução e maior demanda das principais soluções Apache como Spark, Kafka e Flume, as funções de migração de dados que tornaram Sqoop essencial para projetos de Big Data começaram a ser disponibilizadas de forma nativa nestas e outras soluções, o que colaborou para a aposentadoria do Apache Sqoop.

É importante reforçar que o Sqoop ainda é amplamente utilizado e ajudou no desenvolvimento das tecnologias atuais, portanto, entender como o Sqoop funciona é importante por diversos motivos.

Como aplicar na prática o que aprendeu

Manual do sqoop. https://sqoop.apache.org/docs/1.4.6/SqoopUserGuide.html.

Casos de uso do sqoop. https://thirdeyedata.ai/apache-sqoop/.

Usos práticos de Sqoop. https://www.linkedin.com/pulse/sqoop-use-case-hariharan-ramachandran/.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Conheça os projetos aposentados no Apache Attic. https://attic.apache.org/projects/sqoop.html.

Apache Sqoop no ambiente AWS. https://docs.aws.amazon.com/pt_br/emr/latest/ReleaseGuide/emr-sqoop.html.

Tutorial avançado de Sqoop. https://www.tutorialspoint.com/sqoop/index.htm.

Referência Bibliográfica

CHEN, Liu; KO, Junghyun; YEO, Jeongmo. **Analysis of the Influence Factors of Data Loading Performance Using Apache Sqoop**. KIPS Transactions on Software and Data Engineering. 4. 77-82. 10.3745/KTSDE.2015.4.2.77. 2015.

BHUPATHIRAJU, Vijayalakshmi; RAVURI, Ravi. **The dawn of Big Data - Hbase**. 1-4. 10.1109/CSIBIG.2014.7056952. 2014.

VOHRA, Deepak. **Apache Sqoop**. 10.1007/978-1-4842-2199-0_5. 2016.

VOHRA, Deepak. **Using Apache Sqoop**. 10.1007/978-1-4842-1830-3_11. 2016.

Ir para questão