# Engenharia de dados com Spark

## Introdução

Entenderemos o conceito de Engenharia de Dados e aprenderemos como usar Spark em suas diferentes funcionalidades dentro desta área.

### Objetivos da aula

- Conhecer a ferramenta de Engenharia de dados Apache Spark.
- Praticar a criação de um projeto de engenharia de dados.

### Resumo

Apache Spark é uma *engine* ou um motor de processamento de dados muito poderoso. Descobriremos juntos todas as suas características e vantagens para a engenharia de dados, mas vamos entender o que é a Engenharia de Dados comparada com outras áreas. É importante notar que essas atribuições variam levemente de empresa para empresa e de indústria para indústria, onde uma pessoa pode ter mais atribuições do que outra ou até mesmo assumir duas das posições listadas abaixo, o que não é ideal.

## Cientista de Dados

Esta é a pessoa que lida com grandes volumes de dados desestruturados e trabalha para não apenas tratar Big Data sob demanda, ou seja, conforme chega, mas também cria regras e aplica modelos analíticos e de Machine Learning de acordo com a necessidade do negócio para que tais processos sejam automatizados e gerem inteligência da forma mais automatizada o possível. Dependendo da escala do projeto, o cientista de dados deverá trabalhar com um Engenheiro de Dados para a criação de um ambiente como Hadoop, Spark ou outras soluções Apache ou similares para aumentar a escala de suas soluções.

## Engenheiro de Dados

Geralmente esta pessoa começa a atuar no início da esteira e atua durante todo o ciclo de vida dos dados. Esta pessoa é essencialmente responsável pelo desenvolvimento do ambiente ou pipeline de processamento de dados de acordo com as especificidades de negócios, que geralmente serão desenvolvidas em parceria com Cientistas de Dados. Resumidamente, esta pessoa é responsável por transformar regras de ETL em ambientes automatizados de coleta, tratamento e armazenamento de dados para geração de insights em tempo real ou em bases de dados de inteligência armazenada para posterior consulta.

## Analista de Dados

A pessoa de análise de dados, Business Intelligence (BI) ou suas variações vai atuar mais na ponta final de todo o processo processamento de dados, pois será a pessoa responsável em gerar insights menos padronizados e mais “leigos” para pessoas não técnicas. Ainda assim, precisará entender conceitos de Data Warehousing, Programação, Base de dados e conceitos de estatística.

Agora que você já entendeu a diferença entre as três principais áreas relacionadas a dados, agora é hora de nos aprofundarmos na Engenharia de dados da perspectiva do Apache Spark, que é o principal motor para a criação de ambientes de processamento de dados com diversas vantagens sobre os sistemas mais tradicionais, como veremos a seguir.

O paradigma de programação *mapreduce* que representa uma forma de programar em Python e linguagens parecidas para literalmente mapear dados e então reduzi-los em quantidade para gerar dados mais rapidamente é largamente conhecido e é já foi revolucionário para sua época, mas possuía algumas limitações por ser geralmente dependente do disco rígido ao invés de memória RAM, que é extremamente mais rápida.

Com Spark, as operações e soluções em Python podem processar dados até 100 vezes mais rapidamente quando utilizando apenas memória RAM e até 10 vezes mais rápido quando combina RAM e disco rígido. Além da utilização da memória RAM, Spark tem uma vantagem que é a criação de clusters ou grupos de processamento, que quebra grandes volumes de dados e os processa simultaneamente, acelerando a velocidade de geração de insights. Vamos conhecer algumas outras características de Spark.

## Imutabilidade

Spark possui um sistema de tolerância a falhas que contribui para maior segurança e integridade de dados. Seu sistema gerenciador de dados chamado *Resilient Distributed Datasets* (RDD) em colaboração com DAG ou Directed Acyclic Graphs, permite que as ações sejam quebradas em partes menores e suas versões sejam temporariamente armazenadas, para que os dados voltem à sua versão original antes da ação em caso de erro ou falha técnica.

## Transformações e Ações

Um conceito muito valioso para o melhor desempenho de Spark, Transformações pegam um dado como entrada e criam diversas versões deste mesmo dado para resultado. Ações são operações executadas nestes dados para transformá-los efetivamente e gerar insights. Esse conceito é importante, pois se uma ação precisa ser executada em diferentes versões de dados, ela espera até que todas estas versões estejam disponíveis para *trigar* ou ativar a operação transformadora, economizando assim poder de processamento e armazenamento.

## Directed Acyclic Graph

Uma nova alternativa ao tradicional MapReduce, que tem o potencial de não depender de armazenamento em disco rígido e armazena mais dados sobre a operação de mapeamento, filtro e redução e estágios dos dados, o que ajuda a tornar Apache Spark mais rápido e *fault-tolerant* (tolerante a falhas).

### Apache Spark Core

É o centro de operações de Spark. Organiza todos os outros módulos como o de processamento SQL, Streaming, Gestão de dados e processamento em memória.

### Spark SQL

É o módulo responsável pela integração com bases de dados relacionais.

### Spark Streaming

É o módulo responsável por processamento em *real-time* ou tempo real. Pode se conectar com Apache Kafka e diferentes outras soluções para gerar insights e tomadas de decisão em tempo real.

### MLlib (Machine Learning Library)

Spark possui uma rica biblioteca de Aprendizado de Máquina ou Machine Learning.

### Como aplicar na prática o que aprendeu

Nesta fase, é importante entender o que é Apache Spark. Este é um software utilitário como Google Colab ou Anaconda, ou seja, q dependerá de códigos Python e outras soluções em código para funcionar corretamente. A diferença é que Spark é extremamente mais poderoso. É possível instalar em seu computador comum, mas você notará seu poder quando combinado a ambientes cloud como o AWS.

**Material extra**

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

**Conteúdo bônus**

Introdução ao Spark.

Básico da programação em Spark e excelente canal para seguir.

**Tópicos avançados**

- Configure um ambiente Spark em seu computador ou na nuvem (link);
- Rode códigos básicos de Python para entender o funcionamento (link);
- Crie um projeto real do zero seguindo instruções (link)

- Procure por projetos avançados em sites como Kaggle, Github Stackoverflow e ProjectPro.

Referência Bibliográfica

VORA, Shreyash. **Know About Apache Spark Using PySpark for Data Engineering**. 2021. Disponível em: https://www.analyticsvidhya.com/blog/2021/07/know-about-apache-spark-using-pyspark-for-data-engineering/. Acesso em 21/12/2022.

Shahrivari, Saeed. **Beyond Batch Processing: Towards Real-Time and Streaming Big Data Computers**. 3. 10.3390/computers3040117. 2014. Disponível em: https://www.researchgate.net/figure/Hadoop-performance-compared-to-Spark_fig1_260801125. Acesso em 21/12/2022.

**Ir para questão**