ETL e Batch ETL as a code com Python

Introdução

Neste módulo você aprenderá como fazer o processo de extração, transformação e carregamento de dados (ETL) e suas formas variantes tanto com arquivos individuais como com diversos arquivos através do processamento em batch.

Objetivos da aula

- Introdução teórica do que ETL.
- Praticar o processo de ETL simples.
- Praticar ETL em batch através de código python.

Resumo

Provavelmente você já ouviu falar do processo chamado ETL (*Extract, transform, load)* ou extrair, transformar e carregar. Este foi o processo padrão que definiu o rumo das ciências de dados e analytics por muito tempo. Esse processo define as etapas para coleta, extração e tratamento ou limpeza de dados para que possamos gerar inteligência deles de forma padronizada.

Por mais conhecido que esse processo seja, ele ainda causa um pouco de confusão em algumas pessoas, especialmente iniciantes. Por isso vamos revê-lo antes de entender conceitos mais avançados. ETL não é uma ferramenta ou software específico. De fato, você pode realizar o processo de ETL até com um bloco de notas ou planilha do google. Sem dúvida será imensamente mais difícil conforme a do que fazer com um ambiente que rode Python, pois conforme a quantidade de dados aumenta, maior será a quantidade de operações manuais que você terá que executar.

Aí está a vantagem do Python e todos os ambientes que o suportam: Automatização. Através destas ferramentas, você criará apenas um código em Python, que extrairá os dados de diferentes fontes pré-determinadas (E de “ETL”). Nesta fase de extração, você definirá, através do Python que tipo de arquivo você deseja processar com Python e a linguagem tratará todos os dados daquele arquivo de forma plana, ou seja, tratará todas as possíveis formatações, divisões e caracteres especiais daquele tipo de arquivo.

Com esta função do Python, você pode até ler diferentes arquivos como .csv, arquivos de maquinários especializados como .dat e de diferentes bases de dados, unindo todos estes dados que naturalmente não seriam compatíveis e não poderiam ser conectados de outra forma ou exigiria tremenda mão de obra para tal conversão. Esse é o início do nosso T e “ETL”, que é muito sutil e passa quase despercebida, pois Python faz isso muito bem sem muita ajuda nossa.

Uma vez coletados e unidos, ainda dentro da fase de transformação, é hora de começar a trabalhar estes dados de forma unificada para gerar inteligência, ou seja, gerar informações que ajudem na tomada de decisões do negócio ou instituição. Esta é possivelmente a fase mais técnica do processo todo, pois exigirá uma certo conhecimento do

negócio, pois você precisa saber quais insights serão necessários e com que prioridade. Você também precisará de conhecimento de Python ao menos uma certa familiaridade com linguagens de programação e sites como StackOverFlow, GitHub e Kaggle para pesquisar soluções e saber como resolver o problema.

Nesta fase de transformação, seu objetivo é criar uma solução em Python que interprete estes dados e crie uma visualização ou dado resultante que ajude em algumas decisões da empresa ou solução que está criando. As possibilidades de resultados vão desde um gráfico de previsão de gastos de clientes e sugestões de preenchimento de estoque até a fluxos automatizados que processam várias bases de dados e geram indicadores simples que podem instruir máquinas e até ditar o trabalho de times inteiros de manutenção preventiva. As possibilidades são realmente diversas e com a internet das coisas e os dispositivos inteligentes, essas possibilidades aumentam exponencialmente enquanto te escrevo este material.

Seguindo o nosso processo de ETL, chegamos no L que é a parte de carregamento. Nesta parte já extraímos os dados originais, os transformamos para geração de inteligência ou decisão e agora vamos armazenar o resultado em uma base diferente para tanto manter os dados originais íntegros, como também para otimizar a utilização dos novos dados que serão usados na tomada de decisão. Em projetos maiores, o local de armazenamento dos dados nesta fase é chamado de data warehouse.

Data warehouses tendem a ser mais rápidas e muitas vezes ficam em soluções na nuvem como Amazon Web Services (AWS) e similares. No processo de ETL existem várias pessoas especialistas trabalhando em diferentes fases e soluções, como a pessoa de DevOps ou infraestrutura que organiza o Data Warehouse, os analistas de dados ou cientistas de

dados que cuidam arquitetam e programam as soluções e engenheiros de dados que podem vestir diversos chapéus durante o processo. Ca você tenha planos de gerenciar projetos e times com essas características, é muito importante entender um pouco de cada fase e saber ao menos a terminologia.

Agora que revisitamos o processo de ETL, vamos entender sua variação, o ELT, que é apenas uma inversão do processo original. Isso significa que ao invés de Extrair, transformar e carregar os arquivos em uma base própria somente depois da transformação, o ELT agora vai extrair e armazenar os dados em uma base mais ágil antes de qualquer transformação. Isso possibilita que diferentes soluções possam usar os dados simultaneamente ou de forma enfileirada, mas com economia de armazenamento e aumento significativo na velocidade de processamento, uma vez que as data warehouses utilizadas são extremamente velozes e *fault-tolerant,* ou seja, conseguem se recuperar de falhas e problemas técnicos sem afetar a integridade dos dados.

Esta nova alternativa vai ao encontro de novas tecnologias de streaming de dados, ou seja, tecnologias que de forma quase que instantânea recebem dados, os transformam e já os disponibilizam para uso e tomada de decisão em tempo real. Como mencionei anteriormente, estamos falando de ideias e processos que podem ser aplicados a diferentes ferramentas e softwares. Uma vez entendida esta fase, fica muito mais fácil trabalhar com as ferramentas ensinadas neste curso para a aplicação de tais processos, que devem ser escolhidos e definidos dentro de sua empresa ou projeto com a ajuda de diversos especialistas e gestores que entendem não só do negócio, mas dos recursos financeiros e tecnológicos à sua disposição.

Como aplicar na prática o que aprendeu

Para a nossa prática, peço que acessem os acervos de códigos em Python e diversas práticas para que você possa entender e praticar o processo de ETL não apenas com arquivos simples, mas também com diversos arquivos.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Caso queira avançar ainda mais no material, recomendo a criação de um ambiente de para processamento de dados como no vídeo destes links.

Medium

Hevodata

Referência Bibliográfica

BLASI, Isabela. ETL X ELT: qual a diferença?. **Indicium**. 2020. Disponível em: https://blog.indicium.tech/etl-vs-elt-diferencas/. Acesso em 12/12/2022

LI, Zhenlong. Big Data Computing for Geospatial Applications. **IJGI**. 2020. Disponível em: https://www.mdpi.com/books/book/3121. Acesso em 12/12/2022

Ir para questão