Gestão e manutenção da qualidade dos dados

Introdução

Vamos entender os conceitos básicos da integridade de dados, que tem como aspecto principal a qualidade dos dados. Vamos aprender, também, como fazer a manutenção para maior integridade e, consequentemente, melhor qualidade de dados.

Objetivos da aula

- Entender o conceito de qualidade de dados
- Realizar aprofundamento teórico com exemplos práticos de quais métricas se observar
- Entender o processo de criação de uma cultura de cultura de dados em organizações

Resumo

Existe uma certa confusão sobre o que é Integridade de Dados e Qualidade de Dados. Algumas pessoas usam os termos como sinônimos e outras acabam dando maior peso para qualidade do que para integridade. É importante entender que Integridade funciona como um guarda chuva e dentro dele veremos: Qualidade de dados, Enriquecimento e Integração de dados. Vamos entender melhor o que cada um é e não é.

Integração de dados

Quando começamos a coletar e disponibilizar dados de e para diferentes unidades de negócios, departamentos e até empresas, é possível que alguns desses grupos percam o acesso holístico aos dados ou não consigam ver a imagem toda. Quando isso acontece, temos um problema de integração de dados. Por isso é importante manter um mapeamento

documentado de quem disponibiliza e quem precisa de diferentes dados em suas diferentes fases de vida.

Enriquecimento de dados

Quando trabalhamos dados para gerar determinadas respostas e insights, podemos enriquecê-lo ainda mais com detalhes que talvez não tenham sido solicitados pelo cliente. Ao adicionar informações demográficas, por exemplo, conseguimos ter uma visualização e possíveis decisões diferentes e melhores do que somente números de vendas, gênero e idade. O enriquecimento dos dados pode acontecer antes mesmo da coleta, em reuniões de *brainstorm* com todos os envolvidos no projeto. Quanto maior o conhecimento do negócio e objetivos, melhor será a sugestão de enriquecimento de dados.

Quando falamos de Qualidade de Dados, é interessante entendermos alguns aspectos interessantes que dados devem ter e como alcançá-los.

Precisão

Os dados estão refletindo a realidade? Essa parece ser uma pergunta simples, mas podemos usar formatações que atrapalham a precisão dos números, como por exemplo pedir apenas a idade ao invés de a data de nascimento. Este é um exemplo simples, mas sem a data de nascimento, teremos apenas a idade da pessoa no momento em que ela forneceu os dados. Por isso, pense em formas de coletar dados que reflitam a realidade por mais tempo possível. Geralmente isso vai acontecer com um planejamento das interfaces de coleta de dados e instrução dos envolvidos e utilizadores das soluções. Uma solução em caso de problemas existentes é buscar por dispositivos de atualização de dados, seja através de integrações com outras bases existentes ou solicitando a entrada manual novamente.

Completude

Os dados são suficientes para o objetivo? Ao analisarmos uma grande base de dados sobre comportamentos de pessoas, por exemplo, é possível que deixemos passar algumas métricas importantes para o seu projeto. É fato que alguns aspectos da realidade não são possíveis ou relevantes de se documentar, mas quanto mais você entender do negócio, melhor será sua descrição da realidade através dos dados. É importante lembrar que os dados sendo coletados agora não serão necessariamente utilizados somente no projeto em que você está

trabalhando, por isso, sempre que possível discuta opções de coleta de dados mais abrangentes para uso futuro.

Confiabilidade

Os dados podem ser confirmados por outras bases confiáveis ou existe contradição? Isso pode acontecer muito em grandes empresas, pois algumas bases informais são alimentadas por um período e com o tempo, a base informal pode refletir a realidade melhor do que bases de dados formais, mas por não haver um padrão na coleta de dados, os dados informais podem perder valor. Por isso é importante criar políticas de armazenamento de dados de forma centralizada e com padrões.

Relevância

Os dados sendo coletados serão realmente necessários? Esta é uma pergunta complexa, uma vez que os objetivos da empresa podem mudar. Por isso, é muito importante que haja um processo de validação com diferentes stakeholders que entendam bem do negócio antes da exclusão de dardos, que também é chamada de Sunset, aposentadoria ou até Purge de dados.

Pontualidade

Os dados estão atualizados? Ao começar a planejar um sistema de coleta de dados, é importante pensar em dispositivos de atualização de dados. Algumas empresas definem quais dados precisam de atualização e podem até colocar prazos de atualização em contrato. É importante entender quais dados precisam ser atualizados e em qual período para evitar a perda de valor por falta de pontualidade dos dados.

Agora que passamos por alguns aspectos importantes dos dados, vamos entender mais sobre algumas operações que podem ocorrer no ciclo de vida dos dados. Algumas empresas já possuem um time de DataOps ou operações em dados, que ficam em grande parte responsáveis por essas operações.

Deduplicação ou desduplicação de Dados

É o processamento de remover dados duplicados para evitar ambiguidades. Deve ser feito com cuidado pois por vezes dados podem parecer duplicados, mas estão servindo diferentes propósitos em projetos distintos ou pior ainda: Parecem ser duplicados, mas não são.

Manutenção de dados

A manutenção de dados é um processo complexo de busca e limpeza de erros para que os dados possam atingir os parâmetros de qualidade que discutimos anteriormente. Na manutenção de dados, busca-se por acessos inadequados aos dados, problemas de formatação, duplicação e todos os problemas que já discutimos.

É de extrema importância manter um processo de manutenção de dados ativo e sempre em constante melhoria, pois só assim é possível garantir um crescimento sustentável sem problemas operacionais e até legais.

Como aplicar na prática o que aprendeu

A gestão e manutenção de dados pode ser algo simples quando a empresa possui boa comunicação, ferramentas e pessoas técnicas. Grande parte da gestão da qualidade de dados gira em torno de decisões iniciais, boa comunicação e protagonismo técnico, que nada mais é que dar voz às pessoas que estão operacionalizando o trabalho com dados.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Webinar sobre Qualidade de Dados (link).

Governança de dados moderna (link)

Uma prática educacional avançada que pode ser como seu portfólio é a criação de boas práticas para manutenção de dados em sua empresa ou em empresas fictícias. Se conhecer alguma empresa que possa usar essa solução, você pode até oferecer o serviço de forma gratuita para servir como seu portfólio e casos de sucesso.

Referência Bibliográfica

CAI, Li; ZHU, Yangyong. The Challenges of Data Quality and Data Quality Assessment in the Big Data Era. **Data Science Journal**. 14. 10.5334/dsj-2015-002. 2015. Disponível: em: https://www.researchgate.net/publication/277943983_The_Challenges_of_Data_Quality_and_Data_Qua Acesso em 21/12/2022

SCANNAPIECO, Monica; MISSIER, Paolo; BATINI, Carlo. Data Quality at a Glance. **Datenbank-Spektrum**. 14. 6-14. 2005. Disponível em: https://www.researchgate.net/publication/220102773_Data_Quality_at_a_Glance. Acesso em 21/12/2022

SIDI, Fatimah *et al*. **Data quality: A survey of data quality dimensions**. 10.1109/InfRKM.2012.6204995. 2013. Disponível em: https://www.researchgate.net/publication/241631252_Data_quality_A_survey_of_data_quality_dimensions. Acesso em 21/12/2022

Ir para questão