Migração e streaming com NiFi

Introdução

Vamos entender como Apache NiFi faz migração de grandes volumes de dados de diferentes plataformas de forma segura e compatível.

Objetivos da aula

- Conhecer a ferramenta de migração e streaming Apache Nifi
- Praticar a criação de um fluxo de streaming com migração de dados em Nifi.

Resumo

Há pouco tempo atrás, era muito difícil pensar em uma migração de dados entre duas Bases de Dados diferentes. Não apenas pelo fato de serem softwares diferentes, como MySQL e PostgreSQL, mas também pelo fato de estarem em servidores remotos, uma vez que a velocidade de transmissão não era tão rápida e ficava ainda mais lenta em conexões seguras para tais migrações.

Diversas soluções foram criadas para amenizar este tipo de problema e facilitar tal migração de forma atrasada ou até mesmo em tempo real. Soluções como MQSeries, que funcionam como um mensageiro universal entre plataformas literalmente traduzia o conteúdo uma Base de Dados, Sistema Operacional ou até mesmo uma plataforma de hardware completamente distinta.

Ainda assim existiam diversos desafios de licença, custo de processamento para plataformas menos robustas e o principal: dificuldade de configuração inicial. Essa dificuldade inviabiliza quase todos os projetos, pois para tornar uma solução de migração de dados viável, o retorno financeiro tinha que ser muito grande e geralmente era difícil de se justificar.

Com o tempo e a evolução da tecnologia, velocidade de internet e demandas em tempo real de aplicações portáteis, tornou-se cada vez

mais viável a criação de soluções de migração e até streaming de dados em tempo real para diferentes plataformas, uma vez que era do interesse dos investidores e desenvolvedores de tais aplicativos que haja cada vez mais velocidade e integração de dados de diferentes plataformas na tomada de decisão e ingestão de dados para aplicativos interativos imediatistas como Uber, iFood e diversos outros que utilizam milhares de pontos de dados para exibir uma informação ao usuário em tempo real.

Para você que está se especializando na área, é muito importante entender alguns conceitos sobre o projeto em que vai trabalhar antes de tomar grandes decisões. Muitas vezes nos apaixonamos por uma ideia ou inovação e acabamos não enxergando a realidade. Falo por experiência própria! Seja você a pessoa que implementa, programa ou gerencia o projeto como todo, faça algumas perguntas cruciais sobre o projeto antes de propor grandes mudanças na empresa ou no projeto, pois se essas mudanças não derem retorno ou no futuro forem canceladas, você pode perder a confiança da empresa e até seu emprego.

Digo isso por experiência própria, pois muitos novos gestores e recém-contratados têm uma vontade grande de inovar e trazer mudanças interessantes para um ecossistema já engessado ou talvez bem funcional dentro de sua realidade. Por isso, não queime suas oportunidades de crescimento na empresa ao propor uma revolução tecnológica antes de entender bem em que estágio a empresa e seus produtos estão, quais os objetivos reais, ou seja, aquele que a diretoria não fala tão abertamente - e como essas tecnologias podem ajudar no curto, médio e longo prazo.

Exemplos destas inovações apaixonantes são Streaming e Migração de dados. Algumas empresas que efetivamente não precisavam destas tecnologias tentam implementá-los só pelo aspecto inovador e algumas acabam até desativando seus ambientes por falta de uso ou retorno financeiro no investimento (ROI). Por mais inovadora que estas tecnologias sejam, implementá-las custa caro e muitas vezes demanda a contratação de novas pessoas e até consultoria no time. Por isso, a principal lição que você pode levar deste curso não é necessariamente como operar e gerenciar estas tecnologias, mas sim quando é a hora de implementá-las.

Se sua empresa ou produto não exige a união de bilhões de dados em tempo real ou a interatividade em tempo real de bases de dados diferentes, muito provavelmente você poderá encontrar outras alternativas para gerenciá-las e melhorar seu desempenho com o time existente ou com leves alterações.

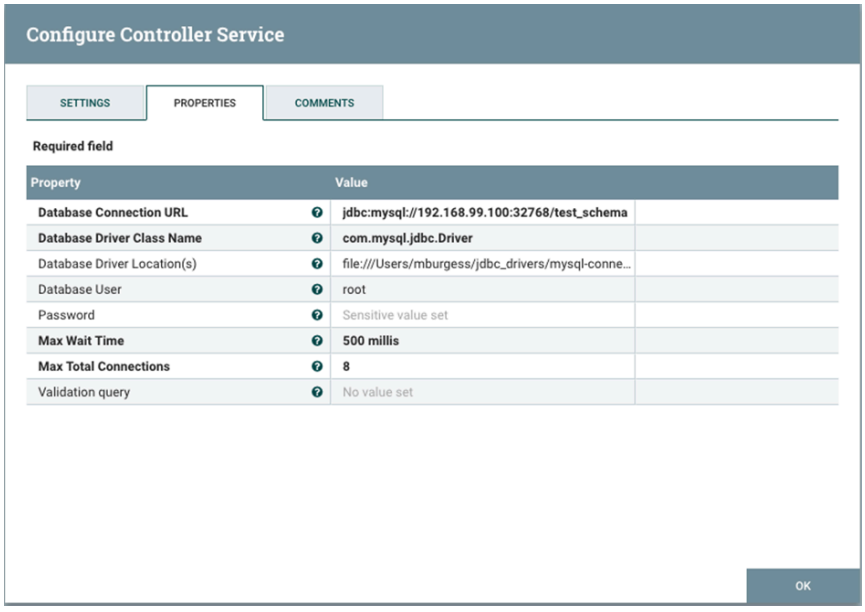
Apache NiFi é uma solução Open Source, ou seja, de código aberto, que permite a migração de grandes volumes de dados entre Sistemas

Gerenciadores de Bancos de Dados distintos e diversos tipos de arquivos. Por mais que não seja a ferramenta mais indicada, NiFi também pode ser usado para streaming.

Isso acontece graças à integração de diferentes processadores internos com a habilidade de se autenticar em diferentes bancos de dados através de drivers especializados que se comunicam com diferentes bases de dados e JDBC ou Java Database Connectivity, que é uma API poderosa para o acesso e manuseio de diferentes bases de dados.

NiFi é um exemplo perfeito de uma solução poderosa, gratuita mas que se implementada sem necessidade, pode se tornar um custo desnecessário. Com a correta implementação de NiFi, é possível ler e copiar uma base de dados inteira de forma segura, relativamente fácil e com integridade de dados. Ao configurar NiFi, seja em seu ambiente cloud como AWS, Cloudera ou até mesmo localmente em seu servidor principal, NiFi permite que você crie URLs que indique onde sua base de dados está localizada juntamente com os drivers necessários para interagir com tal base de dados, como na imagem abaixo.

Imagem 1. Configuração de driver e endereço da base de dados MySQL.



Fonte: https://community.cloudera.com/t5/Support-Questions/how-to-configure-and-connect-mysql-with-nifi-and-perform/m-p/109478. (acesso em 21/12/2022)

Na imagem é possível ver a configuração do JDBC com o driver para MySQL, o endereço de IP do servidor onde se encontra a base de dados.

Como aplicar na prática o que aprendeu

Primeiros passos com Nifi.

Configurando o Ambiente de Nifi.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Futuro dos dados.

Configurando Nifi no AWS.

Referência Bibliográfica

ONAL, Aras. Using Apache NiFi for Migrating Data. **Medium**. 2019. Disponível em: https://medium.com/trendyol-tech/using-apache-nifi-for-migrating-data-fe1c224c7b16. Acesso em 21/12/2022

Apache Foundation. Apache NiFi. **Apache Docs**. 2019. Disponível em: https://nifi.apache.org/docs.html. Acesso em 21/12/2022

Apache Foundation. Apache NiFi. **Apache Docs**. 2019. Disponível em: https://docs.cloudera.com/HDPDocuments/HCP1/HCP-1.9.1/add-new-telemetry-data-source/content/streaming_data_using_nifi.html. Acesso em 21/12/2022

SARABIA, David *et al*. Seaport Data Space for Improving Logistic Maritime Operations. **IEEE Access**. PP. 1-1. 10.1109/ACCESS.2019.2963283. 2019. Disponível em: https://www.researchgate.net/publication/338283140_Seaport_Data_Space_for_Improving_Logistic_Mari Acesso em 21/12/2022

Ir para questão