Streaming distribuído com Kafka

Introdução

Vamos entender o que é Apache Kafka, como funciona e suas vantagens para empresas de médio e grande porte que necessitam de streaming distribuído de dados.

Objetivos da aula

- Conhecer a ferramenta de streaming distribuído Apache Kafka
- Praticar a criação de um fluxo de streaming distribuído.

Resumo

Kafka é uma aplicação do conjunto Apache que colaborou na revolução de como dados são processados e distribuídos. Já falamos de batch e streaming anteriormente e agora é a hora de entendermos melhor o que é o streaming distribuído. Para reforçar o aprendizado, vamos relembrar como modelos tradicionais de distribuição de dados trabalham.

O dado é gerado por uma aplicação, usuário ou até mesmo armazenado em uma base de dados pela empresa de forma ordenada para posterior uso. Sabemos então onde o dado se encontra e diferentes desenvolvedores, gerentes de projetos e produtos começam

a mapear as possibilidades de uso desses dados e começam a desenvolver suas aplicações em volta da utilidade deste dado.

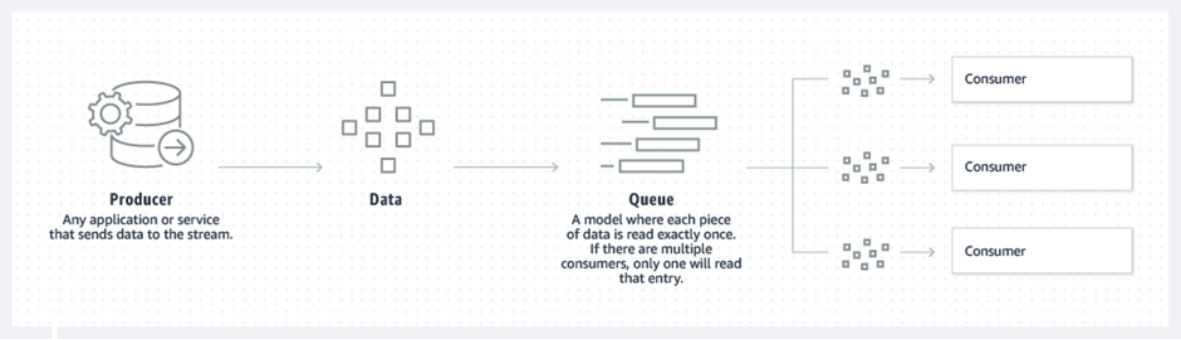
Quando pensamos nos primórdios do desenvolvimento de software, essa utilidade do dado enrijeceu o funcionamento do software desenvolvido, pois muitas vezes as *queries* ou consultas em dados eram compiladas juntamente com a aplicação, o que com o tempo começou a gerar custos de remodelamento e até de completa reconstrução dessas aplicações ou até tentativas de reestruturar inteiras bases de dados e processos de armazenamento e processamento dos mesmos.

Com a evolução das aplicações, cresceram as demandas por fontes de dados cada vez mais voláteis e de fácil transformação. Assim começaram a nascer aplicações cada vez menos engessadas e com interações pré-definidas com os dados. Com esse novo paradigma, nasceu também a necessidade por fontes de dados mais voláteis, fáceis de se transformar só que sem perder os aspectos já conhecidos de Big Data, ou seja: Volume, Velocidade, Variedade, Variabilidade e Veracidade.

Com o nascimento de soluções que permitiam mais dessas características de formas flexíveis, começaram a surgir novas características importantes para os dados como Visualização e Valor dos dados, que nada mais são que a habilidade de entender o propósito e o valor gerado por grandes volumes de dados de forma cada vez mais rápida.

Já existiam diferentes soluções de mensageria, armazenamento de processamento de dados e até interconectividade de bases de dados e plataformas. O problema é que não havia uma união de todas essas tecnologias e tampouco infraestruturas e aplicações que as utilizariam, o

que foi mudando gradualmente. Vamos entender a infraestrutura de sistemas de streaming distribuídos, como Kafka. É importante lembr que existem diversas formas de combinar Kafka com diversas outras aplicações como AWS e suas sub plataformas e soluções parecidas para otimizar o uso de Kafka em diferentes ambientes.



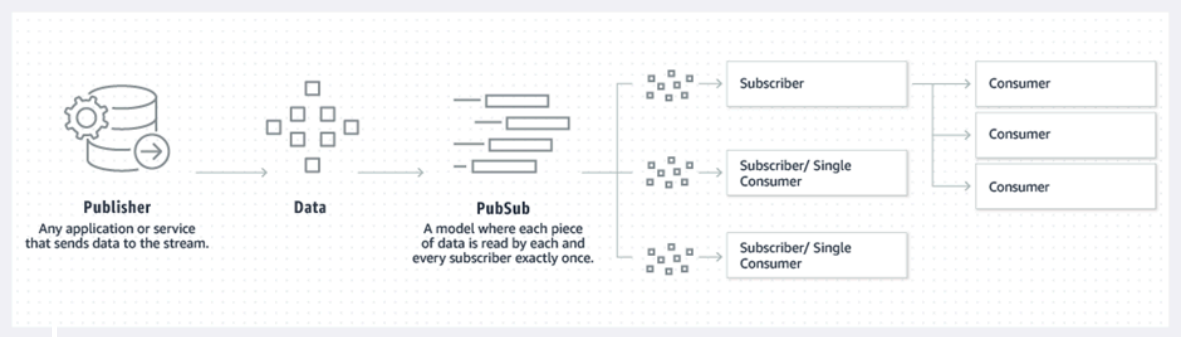
Fonte: AWS. Acesso em 05 de Dezembro de 2022.

Na imagem acima você consegue observar o fluxo de funcionamento de um ambiente de streaming distribuído com uma fila ou *queue.* Neste fluxo, temos todo tipo de produtor de conteúdo como mencionamos no início. Um produtor de conteúdo pode ser uma pessoa manualmente adicionando um dado até uma aplicação que processou os dados de centenas de usuários e guardou apenas insights e decisões. As possibilidades são diversas.

O que temos em seguida são os dados em si, que podem ser pré-processados para fins pré-determinados, a fila que não é necessariamente uma característica obrigatória desses fluxos de dados, como você verá em breve e por fim temos o que seriam Kafka Topics ou Temas de Kafka (tradução livre). Como o nome sugere, dados de temas similares são agrupados nestes *Topics* para acesso mais rápido. O uso de *Topics* muda em cada projeto e empresas, mas seriam o equivalente a um agrupamento de dados de propósitos similares para posterior

acesso mais facilitado por seus consumidores, que assim como produtores de dados, podem ser de diferentes origens e demandas.

A grande vantagem de sistemas como Kafka é a facilidade em satisfazer diferentes necessidades de diferentes plataformas de forma muito rápida, segura e previsível.



Fonte: AWS. Acesso em 05 de Dezembro de 2022.

Na imagem acima você consegue observar um fluxo de dados com Kafka combinado à uma nova solução que diferente da fila ou *queue* que permitia o acesso aos dados mais livremente, agora cria um ambiente de inscritos a diferentes canais ou *topics* de dados. Cada inscrito tem seus consumidores finais que efetivamente usam os dados.

A forma mais rápida de se alcançar a maestria em sistemas como Kafka é sem dúvida a prática combinada à análise de casos reais. Existem diversos profissionais que trabalham dentro do ecossistema Kafka ou em um fluxo de dados como os descritos acima. Por isso, é importante entender como você pode começar a atuar ou adquirir experiência o mais rápido possível para navegar dentro das possibilidades de atuação de sua empresa, projeto ou até mesmo em diferentes empresas pelo mundo todo, já que este é um mercado global que facilmente liga funcionários capazes do Brasil a vagas que pagam em diferentes moedas como dólar.

Vamos entender algumas características do Kafka que podem te ajudar em suas decisões profissionais em diferentes projetos. usa um modo de log particionado, que combina abordagens de fila de mensagens e assinatura de publicação.

- O Kafka fornece escalabilidade permitindo que as partições sejam distribuídas em diferentes servidores.

- Com base em políticas, por exemplo, as mensagens podem ser armazenadas por um dia. O usuário pode configurar esta janela de retenção.

- Vários consumidores podem assinar o mesmo tópico, porque o Kafka permite que a mesma mensagem seja reproduzida por um determinado período de tempo.

- Os tópicos são replicados automaticamente, mas o usuário pode configurar manualmente os tópicos para não serem replicados.

- Cada consumidor recebe informações em ordem por causa da arquitetura de log particionado.

- Kafka usa um protocolo binário sobre TCP.

Fonte: AWS. Acesso em 05 de Dezembro de 2022.

Como aplicar na prática o que aprendeu

A instalação do ambiente pode ser uma tarefa útil independente de sua atuação. https://www.youtube.com/watch?v=yIjXO05Y-B0.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Aplicação prática de Kafka com Upsolver. https://www.upsolver.com/blog/apache-kafka-use-cases-when-to-use-not.

Aplicação prática de Kafka em múltiplas indústrias. https://www.kai-waehner.de/blog/2020/10/20/apache-kafka-event-streaming-use-cases-architectures-examples-real-world-across-industries/.

Referência Bibliográfica

NARKHEDE, Neha. Flink and Kafka Streams: a Comparison and Guideline for Users. **Confluent.io**. 2016. Disponível em: https://www.confluent.io/blog/apache-flink-apache-kafka-streams-comparison-guideline-users.

What is Apache Kafka?. **AWS**. 2022. Disponível em: https://aws.amazon.com/msk/what-is-kafka/.

Apache Kafka Practical Uses. **Apache Foundation**. 2022. Disponível em: https://kafka.apache.org/uses/.

Ir para questão