Streaming e processamento em batch

Introdução

Vamos conhecer mais sobre as tecnologias de processamento de dados, a diferença entre processamento individual, processamento em batch e streaming de dados.

Objetivos da aula

- Apresentação dos conceitos teóricos de processamento em batch.
- Conhecimentos de streaming de dados.
- Realizar uma comparação das principais ferramentas apresentadas no curso.

Resumo

Em 2011, tive minha primeira interação com processamento de dados. Me lembro como conceitos de processamento em batch e streaming eram tão abstratos e exclusivos a grandes empresas e projetos multimilionários. Hoje, poucos anos depois, qualquer pessoa de sua própria casa pode montar um ambiente gratuito para começar a processar grandes volumes de dados próprios, ou da internet, que

reproduzem praticamente os mesmos resultados que via em grandes empresas como Delta linhas aéreas, a fabricante de rede de lojas roupas The GAP e diversas outras empresas que faziam esse tipo de processamento desde os primórdios destas tecnologias.

Começo nossa interação com esse relato nostálgico, pois tenho muita alegria em criar este conteúdo, mas gostaria de alertar você que as tecnologias não param! Se hoje usaremos o ecossistema Apache, logo estas tecnologias serão alteradas e possivelmente melhoradas. Isso não significa que você terá que necessariamente reaprender tudo, pois ao entender conceitos básicos de como essas ferramentas funcionam e seu propósito, será muito fácil se adaptar às mudanças.

Um dos conceitos mais importantes e praticamente imutáveis são os tipos de processamento. Você pode tentar entender toda a arquitetura do hadoop, como spark e outros softwares distribuem poder de processamento entre nós e até mesmo decorar aspectos bem específicos de seu funcionamento. Esses detalhes podem mudar, mas seus propósitos continuarão os mesmos, ou seja, processar arquivos de forma singular, coletiva ou em tempo real (streaming). Por isso vamos falar dos tipos de processamento agora.

O processamento de dados tem como objetivo gerar inteligência sobre arquivos individuais, trabalhar suas formatações para que haja um padrão inteligível e então une, resume ou faz diferentes outras operações para gerar inteligência deste volume maior de dados através de algoritmos de análise de dados, aprendizado de máquina e inteligência artificial, que geralmente são escritos em Python ou R.

A escolha entre processamento simples (apenas um arquivo por vez), processamento em batch (vários arquivos de uma vez ou enfileirados) e streaming de arquivos vai depender da quantidade de arquivos,

urgência de ter o resultado do processamento e até mesmo a frequência de tal processamento. Se você estiver trabalhando em um projeto bem específico sem probabilidade de se repetir com os mesmos padrões, muito provavelmente usará ferramentas de processamento individual como Google Colab, Anaconda, Power BI e até mesmo Excel e Google Sheets, por exemplo. Um exemplo disso seria a compreensão de diferentes planilhas com feedback de um evento que você organizou e não acredita que vai se repetir. Neste caso, você poderia usar qualquer uma dessas ferramentas para entender os dados destas planilhas e até gerar insights através de Power BI, gráficos do excel / sheets e até criar soluções mais avançadas com linguagem python ou R.

O processamento em batch, porém, tem um aspecto mais automatizado. Isso significa que há um padrão nos tipos de arquivos enviados, no resultado esperado e até mesmo nas fontes de dados. Um bom exemplo disso é uma fábrica que precisa gerar relatórios de desempenho e manutenção preventiva toda quarta-feira de manhã e para isso usa todos os dados gerados pelos sensores das máquinas em arquivos no formato .csv (comma separated values), que têm seus itens separados por vírgulas. Além dos sensores, os relatórios levam em consideração os arquivos de desempenho dos funcionários inseridos em um sistema ERP e um relatório gerencial semanal que consistem em basicamente perguntas fechadas cujas respostas são “sim” ou “não”. Com estes dados, o ambiente já está preparado para gerar um relatório simples que indica se as máquinas precisam ser verificadas e se o desempenho está abaixo ou acima da média para posterior avaliação humana.

Isso acontece através de um gatilho ou *trigger* que chamamos de *job*. Um job de processamento em batch é um programa que define todas as expectativas, fontes de dados, operações de formatação de dados e geração de resultados. Quanto mais padronizado é um cenário, mais

recorrente será a utilização de um job em particular. Um ambiente de processamento batch pode rodar diversos jobs para diferentes objetivos mas por trabalhar com grandes volumes de dados, a recomendação é que esses jobs rodem em horários alternativos ao dos funcionários e outras aplicações que precisam de poder de processamento.

Quando falamos de streaming ou transmissão em tempo real de dados, estamos basicamente falando de um processamento batch sem a espera. Imagine se você fosse pedir um Uber ou Lyft e tivesse que esperar pela próxima janela de processamento batch para saber o valor e tempo de espera para a rota que você escolheu. Não seria ideal, não é mesmo? É exatamente aí que entra o streaming. Quando diferentes fontes de dados estão mudando e precisam de um processamento instantâneo para geração de inteligência, usamos streaming ao invés de batch.

Existem vários exemplos além dos aplicativos de corridas que geram o custo e estimativas de tempo em tempo real através do processamento imediato de dados do passageiro, do motorista, da rota desejada, das bases de dados de segurança, de outros motoristas fazendo rotas similares e diversos outros dados. Um segundo exemplo interessante é a geração em tempo real de *insights* e dashboards de criadores de conteúdo do Youtube e outras plataformas sociais e anúncios pagos.

As possibilidades aumentam a cada dia, o que é extremamente empolgante, uma vez que com o conhecimento adquirido aqui na Descomplica, você poderá ter uma carreira antifrágil e atuar no desenvolvimento, gestão e até suporte de tecnologias existentes e diversas outras que ainda estão em desenvolvimento. Graças a soluções abertas como o ecossistema Apache, a inovação não está mais limitada apenas aos grandes empresários. Diversos projetos individuais estão sendo desenvolvidos e alguns chamam atenção de

grandes investidores. Alguns exemplos mais promissores são prevenção de fraudes e problemas técnicos em maquinário pesado e tempo real e prevenção e atendimento emergencial com base em dados de *wearables* como relógios inteligentes e outros dispositivos.

Como aplicar na prática o que aprendeu

Recomendo a procura por exemplos de processamento em batch e streaming em sua indústria - a que você atua ou deseja atuar. É muito importante entender exatamente a aplicação de cada um desses tipos de processamento e como os grandes *players* de sua indústria estão fazendo. Assim, você desenvolve um acervo mental para tomadas de decisão em projetos futuros, ideias para entrevistas e fica sempre por dentro de sua indústria.

Material extra

Os códigos utilizados ao longo das aulas estão disponíveis no GitHub da disciplina: https://github.com/FaculdadeDescomplica/Data-Integration-Ingestion-e-Quality

Conteúdo bônus

Tópicos avançados

Alguns desafios do processamento streaming que estão na cabeça dos especialistas.

1. Disponibilidade

Não apenas os dados precisam ser acessados no momento em que são registrados, mas também precisam ser registrados em um armazenamento de dados que manterá essas informações para posterioridade. Um exemplo disso é um sistema de assinatura mensal. O dado sobre renovação de assinaturas é muito importante, mas precisamos visualizar os períodos de assinatura anteriores para termos uma visão completa do histórico de compras e não perder oportunidades de oferecer outros produtos ou serviços valiosos para o usuário. Fazer esse tipo de registro duplo custa processamento e pode falhar às vezes.

2. Pontualidade

Os dados processados em tempo real em fluxos de dados se tornarão obsoletos, por isso é fundamental que sua solução contabilize as informações mais recentes e atualize seus algoritmos de acordo. Por exemplo, você quer que o usuário adicione itens a um carrinho em uma guia, mas o carrinho pode ficar vazio se ele abrir o site em uma guia diferente, pois sua sessão ainda não foi atualizada no servidor.

3. Escalabilidade

Quando se usa streaming, assume-se que o volume de dados é imenso, por isso é importante garantir que armazenamento e processamento estejam prontos para funcionar mesmo em situações extremas. É inaceitável perder dados valiosos porque um pico temporário no volume ou interrupção do sistema sobrecarregaram sua estrutura. Por isso é fundamental criar proteções contra falhas em seu sistema para fornecer recursos extras de computação e

armazenamento para lidar com essas exceções. Os ambientes Apache são famosos por serem *fault-tolerant* ou tolerantes a falhas como essa. Entenderemos mais nos módulos especializados.

4. Integração & solicitação em tempo real

Com muitos dados sendo coletados constantemente, a tendência é priorizar os dados mais recentes. No entanto, o contexto histórico é importante. Gravar uma sequência de interações em sua base de dados ou no CRM (software de gestão de relacionamento com usuários) pode oferecer *insights* mais profundos do que ver que uma pessoa visitou sua página. Assim você vê que eles visitaram uma página da Web do produto depois de baixar dois eBooks relacionados e assistir um vídeo institucional. Agora, o interesse deles fica muito mais claro para você e sua equipe de vendas, pois vários eventos com diferentes pesos foram registrados e agora você pode classificar potenciais clientes com mais certeza.

Referência Bibliográfica

LAWTON, George. 7 enterprise use cases for real-time streaming analytics. **Tech Target.** 2019. Disponível em: https://www.techtarget.com/searchbusinessanalytics/feature/7-enterprise-use-cases-for-real-time-streaming-analytics. Acesso em 09/12/2022

ANDERSON, Sean. What is Streaming Data Analytics? Use Cases, Examples, and Architecture. **Tech Target**. 2022. Disponível em:

https://streamsets.com/blog/what-is-streaming-analytics/. Acesso em 09/12/2022

Ir para questão